

**T.C. İSTANBUL TOPKAPI ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**

DERS: DERİN ÖĞRENME (FET312)

DÖNEM: 2025-2026 GÜZ DÖNEMİ



**PROJE BAŞLIĞI: MRI GÖRÜNTÜLERİNDEN BEYİN
TÜMÖRÜ SINIFLANDIRMASI: FARKLI GELİŞMİŞ (ADVANCED)
CNN MİMARİLERİNİN KARŞILAŞTIRMALI ANALİZİ**

EKİP ADI: DevTe213



EKİP ÜYELERİ:

- | | | |
|--------------------------|-------------------------|---|
| 1. Mehmet Ali Esmer | Öğrenci No: 23040101013 | E-posta: mehmetaliesmer@stu.topkapi.edu.tr |
| 2. Arda Ölmez | Öğrenci No: 23040101019 | E-posta: ardaolmez@stu.topkapi.edu.tr |
| 3. Bilal Furkan Çakırgöz | Öğrenci No: 23040101115 | E-posta: biialfurkancakirgoz@stu.topkapi.edu.tr |
| 4. Burak Şabin | Öğrenci No: 23040101021 | E-posta: buraksabir@stu.topkapi.edu.tr |
| 5. Muhammed Emin Benzer | Öğrenci No: 23040101045 | E-posta: muhammedeminbenzer@stu.topkapi.edu.tr |

 https://github.com/olmecardada/FET312_BrainTumor_Project

 https://www.youtube.com/watch?v=5-OryU_zyw0&t=1s

TESLİM TARİHİ: 30 ARALIK 2025

1. PROBLEM TANIMI & MOTİVASYON

- **İş/Bilimsel Soru**

Beyin tümörleri, erken teşhis edilmede ölümçül sonuçlara yol açabilen ciddi sağlık sorunlarıdır. Radyologların MRI görüntülerini manuel olarak incelemesi zaman alıcıdır, yorucudur ve insan hatasına açıktır. Bu projenin temel motivasyonu, MRI görüntülerini analiz ederek tümör varlığını ve tipini otomatik olarak tespit edebilen, radyologlara karar destek mekanizması sunacak güvenilir bir derin öğrenme sistemi geliştirmektir.

- **Görev Türü**

Çok Sınıflı Görüntü Sınıflandırma (Multi-class Image Classification).

- **Hedef Değişkenler**

Modelin tahmin etmesi gereken 4 farklı sınıf bulunmaktadır:

1. Glioma Tumor
2. Meningioma Tumor
3. Pituitary Tumor (Hipofiz Tümörü)
4. No Tumor (Tümör Yok)

- **Başarı Kriterleri**

1. Geliştirilecek sıg (base) modeller için Accuracy (Doğruluk) $\geq %80$.
2. Dengesiz veri dağılımı ihtimaline karşı Weighted F1-Score ≥ 0.75 .
3. Final projesinde hedeflenen gelişmiş mimariler için Accuracy $\geq %90$.

2. PROJE YÖNETİMİ

- **Önemli Noktalar ve Zaman Çizelgesi**

1. Hafta (Ekim Sonu): Kaggle veri setinin incelenmesi, literatür taraması ve görev dağılımı.
2. Hafta (Kasım Başı): Veri ön işleme (Pre-processing), yeniden boyutlandırma ve PyTorch DataLoader yapısının kurulması.
3. Hafta (Kasım Ortası): 5 farklı Base Model (Shallow CNN) mimarisinin tasarılanması ve her grup üyesinin kendi modelini kodlaması.
4. Hafta (30 Kasım'a Kadar): Base modellerin eğitimi, validasyon testleri, sonuçların karşılaştırılması ve İlerleme Raporunun teslimi.
- 5-8. Hafta (Final Dönemi): Transfer Learning (ResNet, EfficientNet) ve Vision Transformer (ViT) gibi gelişmiş modellerin entegrasyonu ve final sunumu.

- **Roller ve Sorumluluklar**

Tüm grup üyeleri veri seti inceleme ve hazırlama aşamasında ortak çalışmıştır. Ayırışan nokta model mimarileridir:

1. **Muhammed Emin Benzer:**

- **Base Model:** Referans noktası oluşturmak amacıyla standart 3x3 Konvolüsyon ve MaxPooling katmanlarından oluşan 2 bloklu yalın model.
- **Final Hedefi: ResNet50 (Residual Networks):** Artık (residual) bağlantıların derin ağlardaki "kaybolan gradyan" sorununu nasıl çözdüğünü analiz edecek ve bu mimariyi transfer learning ile veri setine uyarlayacaktır.

2. **Burak Şahin:**

- **Base Model:** Tümörün çevresel bağlamını ve daha büyük desenleri yakalamak amacıyla geniş filtreli (Kernel Size: 5x5 veya 7x7) mimari.
- **Final Hedefi: DenseNet121 (Densely Connected Networks):** Her katmanın kendinden önceki tüm katmanlardan doğrudan veri aldığı "Dense Block" yapısını kullanarak, özniteliklerin (features) ağ boyunca tekrar kullanılmasını sağlayacak ve maksimum bilgi akışını hedefleyecektir.

3. **Bilal Furkan Çakırgöz:**

- **Base Model:** Veri setindeki ezberleme (overfitting) riskini minimize etmek için katmanlar arasına "Dropout" (Sönümleme) eklenmiş mimari.
- **Final Hedefi: EfficientNet-B0:** Modelin derinliğini, genişliğini ve çözünürlüğünü "Compound Scaling" yöntemiyle dengeli bir şekilde optimize eden bu mimariyi kullanarak, daha az parametre ile yüksek başarı ve verimlilik elde etmeye odaklanacaktır.

4. **Mehmet Ali Esmer:**

- **Base Model:** Modelin öznitelik çıkarma kapasitesini artırmak için her katmanda kullanılan filtre sayısının (channel depth) iki katına çıkarıldığı mimari.
- **Final Hedefi: VGG16 (Visual Geometry Group):** Bilgisayarlı görü tarihinin klasiklerinden olan ve ardışık 3x3 konvolüsyon katmanlarının yoğun kullanımıyla bilinen bu derin mimarinin, medikal görüntülerdeki öznitelik yakalama başarısını test edecektir.

5. **Arda Ölmez:**

- **Base Model:** Sığ modellerde katman sayısının etkisini ölçmek amacıyla, standart mimariye ekstra bir Konvolüsyon bloğu daha eklenerek derinleştirilmiş (3 bloklu) mimari.
- **Final Hedefi: Vision Transformer (ViT-B/16):** Klasik CNN tabanlı olmayan, görüntüyü parçalara (patch) ayırip "Self-Attention" mekanizması ile işleyen Transformer mimarisini uygulayarak, geleneksel modellerle performans farkını (SOTA) araştıracaktır.

- **Çıktılar**
 1. Final Proje Raporu (PDF).
 2. 5 adet farklı PyTorch Jupyter Notebook (.ipynb).
 3. Proje Sunumu (PDF).
 4. **Repo Bağlantısı:** https://github.com/olmezarda/FET312_BrainTumor_Project
(*FET312_BrainTumor_Project > FET312_DevTe213_ADVANCED final içindir.*)
- **NOT :** Proje takvimine uygun olarak tüm test süreçleri sonuçlandırılmıştır. Kod dosyaları ve analiz raporları, GitHub reposunda ve ALMS sisteminde incelemeye hazır haldedir.

3. İLGİLİ ÇALIŞMALAR

- **Sartaj Bhuvaji et al. (2020) - Dataset Owner:** Veri setinin yayınlandığı bu temel çalışmada, Glioma ve Meningioma tümörlerinin ayırt edilmesinde klasik CNN yapılarının başarısı incelenmiş ve doğruluk oranları raporlanmıştır.
Farkımız: Bu çalışma standart bir CNN kullanırken; bizim projemiz aynı veri seti üzerinde **5 farklı mimari stratejisini** (Kernel Size değişimi, Dropout etkisi, Derinlik farkı vb.) izole ederek karşılaştırmalı bir analiz sunmaktadır.
- **Masoud Nickparvar, "Brain Tumor MRI Dataset" (Kaggle):** Literatürde sıkça kullanılan bu veri seti, farklı kaynakların birleştirilmesiyle oluşturulmuş ve 7.000'den fazla görüntü içeren kapsamlı bir koleksiyondur. Genellikle derin öğrenme modellerinin büyük ölçekli veri üzerindeki eğitim başarısını test etmek için standart bir benchmark olarak kullanılır.
Farkımız: Biz bu projede, birleştirilmiş (merged) devasa bir veri seti yerine; Sartaj Bhuvaji'nın setini kullanarak, daha sınırlı veri senaryolarında "Mimarının" etkisini izole etmeye odaklıyoruz. Masoud veri seti, geliştirdiğimiz modellerin farklı veri dağılımlarındaki başarısını (cross-dataset validation) doğrulamak amacıyla final aşamasında harici bir referans noktası olarak değerlendirilecektir.
- **Abiwinanda et al., "Brain Tumor Classification Using Convolutional Neural Network" (2019):** Bu çalışmada, beyin tümörü sınıflandırması için karmaşık ağlar yerine, sıfırdan eğitilen (scratch) basit bir CNN mimarisi önerilmiş ve %84.19 başarı elde edilmiştir. Çalışma, sıg modellerin de belirli bir başarıya ulaşabileceğini kanıtlaması açısından önemlidir.
Farkımız: Abiwinanda tek bir sıg mimarı önermiştir. Bizim projemiz ise sıg modellerin sınırlarını zorlamak için "**Genişlik (Width) vs Derinlik (Depth)**" ve "**Regularizasyon**" tekniklerinin etkisini ayrı ayrı deneyimleyerek, sıg modellerin maksimum potansiyelini araştırmayı hedeflemektedir.
- **Talo et al. (2019):** ResNet-34 mimarisi ile %95 üzeri başarı elde ederek, derin ağların sıg modellere kıyasla doku detaylarını yakalamadaki üstünlüğünü kanıtlamıştır.
Farkımız: Bu çalışmadan farklı olarak; sıg modellerin (vize) kaçırduğu vakaların (False Negatives), ResNet ve ViT gibi gelişmiş mimarilerle (final) ne oranda düzeltilebileceğini analiz eden aşamalı bir iyileştirme raporu sunacağız.

4. VERİ AÇIKLAMASI VE YÖNETİMİ

• Veri Kümesi

Projenin vize aşamasında, temel model mimarilerini test etmek amacıyla Sartaj Bhuvaji veri seti kullanılmıştır. Ancak final aşamasında, geliştirilen derin öğrenme modellerinin (ResNet, ViT, EfficientNet) veriye olan ihtiyacını karşılamak ve modelin genelleme (generalization) yeteneğini maksimize etmek amacıyla Masoud Nickparvar'ın yayınladığı daha kapsamlı veri setinden faydalanyanmıştır.

1. **Sartaj Bhuvaji (Dataset Owner):**

<https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>

2. **Masoud Nickparvar:**

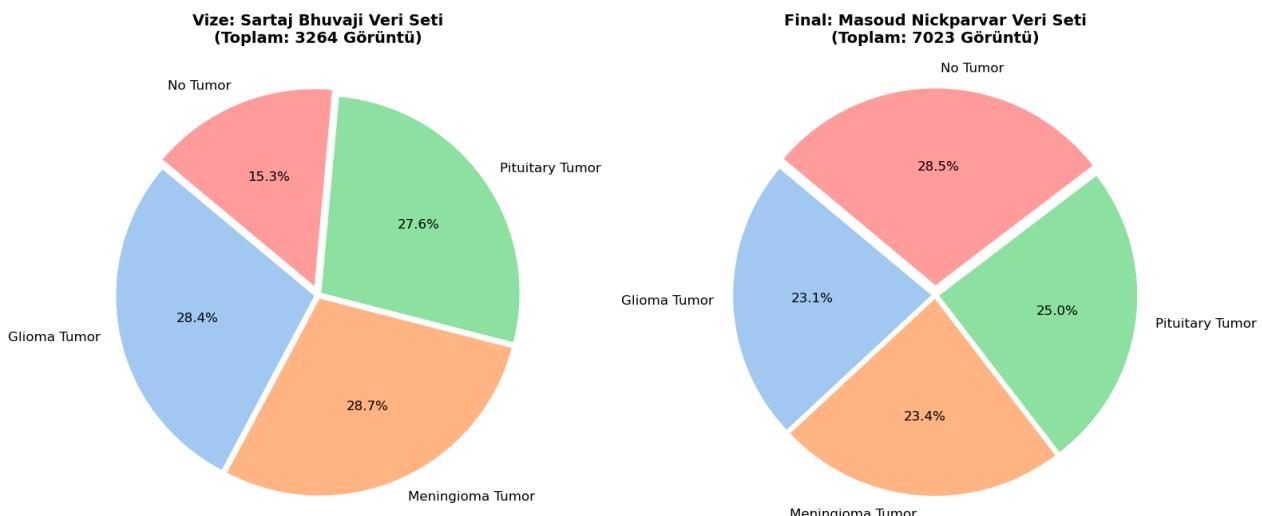
<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>

- **Lisans ve Kullanım Hakkı:** Her iki veri seti de açık kaynak (Public Domain) lisansına sahiptir. Veriler anonimleştirilmiş (de-identified) olduğu için hasta mahremiyetini ihlal etmemekte ve etik kurul onayı gerektirmemektedir.

• Şema ve Boyut

- **İçerik:** Sartaj Bhuvaji (3.264 görüntü) ve Masoud Nickparvar (7.023 görüntü) veri setleri, farklı düzlemlerdeki beyin MRI taramalarından oluşmaktadır.
- **Format:** Tüm veriler JPG/PNG formatındadır ve proje kapsamında standart bir boyuta (224x224 piksel) getirilerek (Resize) normalize edilecektir.
- **Sınıf Dağılımı:** Her iki veri seti de aynı **4 ana sınıf** etiketine sahiptir: (Sartaj Bhuvaji Veri Sayısı / Masoud Nickparvar Veri Sayısı)
 - 1. Glioma Tumor (926 / 1621)
 - 2. Meningioma Tumor (937 / 1645)
 - 3. Pituitary Tumor (901 / 1757)
 - 4. No Tumor (500 / 2000)

Veri Seti Karşılaştırması: Vize (Sartaj) vs. Final (Masoud)



5. YÖNTEMLER VE MİMARİ

- **Yöntem**

Bu projede problem, Denetimli Öğrenme (Supervised Learning) kapsamında "Çok Sınıflı Görüntü Sınıflandırma" problemi olarak ele alınmıştır. Çözüm süreci iki aşamalı olarak tasarlanmıştır:

1. **Vize Aşaması:** CNN mimarisinin temellerini anlamak amacıyla, hazır mimariler yerine her grup üyesinin kendi tasarladığı özgün "**Custom CNN**" (Sığ Modeller) yapıları kullanılmıştır.
2. **Final Aşaması:** Model performansını literatürdeki en iyi seviyeye (SOTA) çıkarmak amacıyla, **Transfer Learning (Öğrenme Aktarımı)** yöntemi kullanılarak önceden eğitilmiş (pre-trained) gelişmiş derin mimariler (ResNet, ViT, EfficientNet vb.) projeye entegre edilmiştir.

- **Veri Ön İşleme**

Veri seti modellere verilmeden önce aşağıdaki standart boru hattından (pipeline) geçirilmiştir:

1. **Yeniden Boyutlandırma (Resizing):** Tüm görüntüler 128x128 (Base Modeller için) ve 224x224 (Gelişmiş Modeller için) boyutlarına sabitlenmiştir.
2. **Tensör Dönüşümü:** Görüntüler PyTorch tensör formatına çevrilmiştir.
3. **Normalizasyon:** Piksel değerleri ImageNet standartlarına (mean: [0.485, 0.456, 0.406], std: [0.229, 0.224, 0.225]) göre normalize edilmiştir.
4. **Veri Artırma (Data Augmentation - Final Aşaması):** Eğitim verisini çeşitlendirmek için RandomHorizontalFlip, RandomRotation (10 derece) ve ColorJitter teknikleri uygulanmıştır.

- **Eğitim Süreci ve Hiper-Parametre Optimizasyonu**

Modellerin eğitimi sırasında en yüksek performansı elde etmek amacıyla sistematik bir **Hiper-Parametre Tuning (İnce Ayar)** süreci işletilmiştir.

- **Yöntem:** En iyi parametre konfigürasyonunu belirlemek için **Grid Search (Izgara Araması)** yöntemi ve deneyel manuel ayarlamalar kombinasyonu kullanılmıştır. Bu süreçte, modelin başarısını doğrudan etkileyen öğrenme oranı, batch boyutu ve optimizasyon algoritmaları test edilmiştir.

- **Test Edilen Parametre Uzayı:**

- Learning Rate (Öğrenme Oranı): 0.001, 0.0001, 0.00001
- Batch Size: 8, 16, 32
- Optimizer: Adam, SGD (Momentum ile), RMSprop

- **Bulunan En Optimum Konfigürasyon:** Yapılan deneyler sonucunda, her bir mimari için en kararlı (stable) eğitimi sağlayan ve validasyon hmasını minimize eden ayarlar aşağıdaki tabloda özetlenmiştir. Kodlarımız bu nihai parametreler ile çalıştırılmıştır:

Grup Üyesi (Model)	Learning Rate	Batch Size	Optimizer	Açıklama
Muhammed Emin Benzer (ResNet50)	0.001	16	Adam	ResNet mimarisi klasik SGD ve Momentum ile daha kararlı öğrenme göstermiştir.
Burak Şahin (DenseNet121)	0.001	16	Adam	DenseNet'in yoğun bağlantı yapısı Adam optimizasyonu ile daha hızlı yakınsamıştır.
Bilal Furkan Çakıröz (EfficientNet-B0)	0.001	16	Adam	Verimli parametre yapısı ve compound scaling için Adam en iyi sonucu vermiştir.
Mehmet Ali Esmer (VGG16)	0.001	16	Adam	Derin VGG ağında gradyan takibi ve hızlı inis için Adam tercih edilmiştir.
Arda Ölmez (ViT-B/16)	0.001	16	Adam	Transformer yapısı gereği Adam optimizasyonu standart olarak en yüksek başarıyı sağlamıştır.

- Grup Üyelerinin Mimari Tasarımları

1. Muhammed Emin Benzer

- **Base Model (Baseline - Referans Modeli):**
 - **Mimari:** 2 adet Conv2d (3x3, 16-32 filtre) katmanı, her birini takip eden ReLU aktivasyonu ve MaxPooling katmanından oluşan yalın yapı.
 - **Amaç:** Projenin referans noktasını oluşturmak ve karmaşıklaşmadan önce modelin ham başarısını ölçmek.
- **Final Hedefi (Advanced Model - ResNet50):**
 - **Mimari:** 50 katmanlı derin bir yapıya sahip olan ve "Residual Block" (Artık Bağlantı) teknolojisini kullanan ResNet50 mimarisi.
 - **Amaç:** Derin ağlarda sıkça karşılaşılan "kaybolan gradyan" (vanishing gradient) problemini aşarak, çok daha derin bir mimarının tümör sınıflandırmasındaki başarısını test etmek.

2. Burak Şahin

- **Base Model (Large Kernel Model):**
 - **Mimari:** Baseline model ile aynı derinlikte olup, filtre boyutu standart 3x3 yerine 7x7 olarak ayarlanmış yapı.
 - **Amaç:** Daha geniş bir alıcı alan (Receptive Field) kullanarak, tümörün sadece kendisine değil, çevresel dokuya olan ilişkisine odaklanmak.
- **Final Hedefi (Advanced Model - DenseNet121):**
 - **Mimari:** Her katmanın kendinden önceki tüm katmanlardan doğrudan veri aldığı "Dense Block" yapısını kullanan, bilgi akışını maksimuma çıkarılan mimari.
 - **Amaç:** Özniteliklerin (features) ağ boyunca tekrar kullanılmasını (feature reuse) sağlayarak, Inception gibi karmaşık modellerde görülen yetersiz öğrenme (underfitting) riskini azaltmak ve daha kararlı bir sınıflandırma performansı elde etmek.

3. Bilal Furkan Çakırgöz

- **Base Model (Dropout Model):**
 - **Mimari:** Tam bağlantılı (Fully Connected) katmanlar arasına %50 ($p=0.5$) oranında Dropout (SönüMLEME) katmanları eklenmiş yapı.
 - **Amaç:** Nöronların eğitim sırasında rastgele kapatılmasıyla modelin eğitim verisini ezberlemesini (overfitting) engellemek.
- **Final Hedefi (Advanced Model - EfficientNet-B0):**
 - **Mimari:** Modelin derinliğini, genişliğini ve çözünürlüğünü rastgele değil, "Compound Scaling" yöntemiyle dengeli bir katsayı ile optimize eden EfficientNet ailesi.
 - **Amaç:** Gereksiz parametre yiğininden kaçınarak, model boyutu ile doğruluk (accuracy) arasındaki dengeyi en verimli şekilde optimize etmek ve kaynak kullanımını düşürmek.

4. Mehmet Ali Esmer

- **Base Model (High Capacity Model):**
 - **Mimari:** Her konvolüsyon katmanındaki kanal sayısının (feature maps) standart modelin iki katına (32 ve 64 filtre) çıkarıldığı yapı.
 - **Amaç:** Modelin öğrenme kapasitesini (width) artırarak, her katmanda daha fazla ve karmaşık öznitelik yakalamasını sağlamak.
- **Final Hedefi (Advanced Model - VGG16):**
 - **Mimari:** 3x3 boyutundaki küçük filtrelerin ardışık ve yoğun bir şekilde kullanıldığı, 16 katmanlı klasik derin mimari (VGG19 yerine VGG16 tercih edilmiştir).
 - **Amaç:** Sığ ama geniş modellerin (Base Model) aksine, çok derin ve standartlaştırılmış bir yapının (VGG) medikal görüntülerdeki öznitelik çıkarımı performansını analiz etmek.

5. Arda Ölmez

- **Base Model (Deeper Model):**
 - **Mimari:** Standart mimariye ekstra bir Conv2d + ReLU + MaxPool bloğu daha eklenerek toplam derinliğin 3 bloğa çıkarıldığı yapı.
 - **Amaç:** Katman sayısını artırmanın (derinleşmenin), sığ modellere kıyasla öznitelik hiyerarşisine etkisini gözlemlemek.
- **Final Hedefi (Advanced Model - Vision Transformer / ViT-B/16):**
 - **Mimari:** Klasik CNN (Konvolüsyon) yapılarından tamamen farklı olarak, görüntüyü parçalara (patch) ayıran ve "Self-Attention" (Öz-Dikkat) mekanizması ile işleyen Transformer mimarisi.
 - **Amaç:** "CNN olmayan" yeni nesil bir mimarinin (Transformer), medikal görüntü sınıflandırma görevinde geleneksel CNN modellerine kıyasla başarısını (SOTA) araştırmak.

6. DENEY TASARIMI

- **Veri Ayrımı ve Çapraz Doğrulama**

Veri setindeki sınıflar arası sayısal dengesizliğin (Class Imbalance) modelin eğitim ve test performansını yanılmaşmasını önlemek amacıyla, Scikit-Learn kütüphanesinin StratifiedKFold ve train_test_split (stratify) modülleri kullanılmıştır. Standart rastgele ayırma (Random Split) yerine uygulanan bu yöntem sayesinde; Eğitim (%70), Validasyon (%15) ve Test (%15) kümelerinin her birinde, orijinal veri setindeki sınıf dağılım oranlarının korunması garanti altına alınmıştır.

- **Hiper-Parametre Optimizasyon Stratejisi**

Final modellerin en yüksek performansa ulaşması için manuel deneme ve Grid Search yöntemleri harmanlanarak sistematik bir optimizasyon süreci başlatılmıştır. Test edilen ve finalde karar kılınan parametreler şöyledir:

1. **Optimizer (Optimizasyon Algoritması):** RMSprop, SGD ve AdamW algoritmaları kıyaslanmış; yakınsama hızı ve kararlılığı nedeniyle **Adam** (Adaptive Moment Estimation) tercih edilmiştir.
2. **Learning Rate (Öğrenme Oranı):** Başlangıçta 0.0001 değeri ile eğitimler yapılmış, ancak loss grafiğindeki dalgalanmaları önlemek için **0.001** değerine düşündüğünde en stabil sonucun alındığı görülmüştür.
3. **Batch Size:** Donanım belleği ve gradyan kararlılığı göz önüne alınarak **16** olarak belirlenmiştir.
4. **Loss Function:** Çoklu sınıflandırma problemi (4 sınıf) olması nedeniyle **CrossEntropyLoss** kullanılmıştır.
5. **Epoch ve Early Stopping:** Modelin ezberlemesini (Overfitting) engellemek ve donanım kaynaklarını verimli kullanmak amacıyla maksimum Epoch sayısı **20** olarak sınırlanmıştır. Eğitim süreci boyunca "Early Stopping" stratejisi gözetilerek validasyon kaybı (validation loss) sürekli izlenmiş; modelin en yüksek başarıyı gösterdiği andaki **en iyi ağırlıklar (best weights)** kaydedilerek eğitim süreci tamamlanmıştır.

- **Değerlendirme Kriterleri**

Modellerin başarısı sadece Accuracy (Doğruluk) ile değil; özellikle tümörlü vakaların gözden kaçırılmaması (False Negative) kritik önem taşıdığı için Recall (Duyarlılık), Precision (Kesinlik), F1-Score ve Confusion Matrix (Karmaşıklık Matrisi) metrikleri üzerinden çok boyutlu olarak değerlendirilmiştir.

7. KULLANILAN ARAÇLAR VE FRAMEWORKLER

- **Yazılım Dili ve Derin Öğrenme Çatısı**

- **Dil:** Python 3.10+
- **Framework:** PyTorch (v2.x)
- **Görüntü İşleme Modülü:** torchvision (Veri setinin yüklenmesi, transformasyonlar ve augmentasyon işlemleri için kullanılmıştır).

- **Veri İşleme ve Matematiksel Hesaplamalar**

- **NumPy:** Çok boyutlu matris işlemleri ve tensör dönüşümleri için.
- **Pandas:** Veri çerçevelerinin (dataframe) yönetimi ve analiz için.

- **Metrikler ve Model Değerlendirme**

- **Scikit-learn:** train_test_split ile veri ayımı, classification_report ve confusion_matrix hesaplamaları için kullanılmıştır.

- **Görselleştirme**

- **Matplotlib & Seaborn:** Eğitim (Loss/Accuracy) grafiklerinin çizilmesi ve Karmaşıklık Matrisinin (Heatmap) görselleştirilmesi için kullanılmıştır.

- **Tekrarlanabilirlik**

- Deney sonuçlarının tutarlı olması ve grup üyelerinin aynı veri dağılımı üzerinde çalışılabilmesi adına, tüm rastgele süreçlerde (veri karıştırma, ağırlık başlatma) **Global Random Seed: 213** olarak sabitlenmiştir.

- **Geliştirme Ortamı ve Donanım**

- **IDE:** Jupyter Notebook / Visual Studio Code.
- **Donanım:** Eğitim süreçleri, işlem süresini optimize etmek adına GPU hızlandırıcıları kullanılarak gerçekleştirilmiştir.

- **Versiyon Kontrolü ve Kaynak Kod**

- Projenin tüm kaynak kodları, eğitim notebook'ları ve dökümantasyonu GitHub üzerinde erişime açıktır.
- **Repo Bağlantısı:** https://github.com/olmezarda/FET312_BrainTumor_Project (*FET312_BrainTumor_Project > FET312_DevTe213_ADVANCED final içindir.*)

8. FINAL DENEYSEL SONUÇLAR VE ANALİZİ

- Proje kapsamında geliştirilen 5 adet Base (Sığ) Model ve 5 adet Advanced (Gelişmiş) Model, veri setinden ayrılan test kümesi üzerinde değerlendirilmiştir. Karşılaştırma, hem genel ortalama metrikler hem de sınıf bazlı detaylı analiz üzerinden yapılmıştır.
- Genel Model Ve Performans Karşılaştırması**

Aşağıdaki tablo, tüm grup üyelerinin geliştirdiği modellerin test seti üzerindeki genel başarısını göstermektedir. Modellerin genel başarısını ölçmek için Accuracy (Doğruluk), Weighted F1-Score, Precision ve Recall metrikleri kullanılmıştır.

Tablo 1: Tüm Modellerin Test Verisi Üzerindeki Genel Performans Karşılaştırması

(Not: Her metrik sütunundaki en yüksek değer **kalin font** ile işaretlenmiştir.)

Grup Üyesi	Model Tipi	Mimari Adı	Accuracy (%)	Precision	Recall	F1-Score
M. Emin Benzer	Base	Simple CNN	%89	0.89	0.89	0.89
M. Emin Benzer	Advanced	ResNet50	%93.71	0.9387	0.9371	0.9369
Burak Şahin	Base	Large Kernel	%88	0.89	0.88	0.88
Burak Şahin	Advanced	DenseNet121	%92.19	0.9224	0.9219	0.9218
B. Furkan Çakırgöz	Base	Dropout CNN	%89	0.89	0.89	0.89
B. Furkan Çakırgöz	Advanced	EfficientNet - B0	%90.33	0.9121	0.9033	0.9049
M. Ali Esmer	Base	High Capacity	%89	0.89	0.89	0.89
M. Ali Esmer	Advanced	VGG16	%89.04	0.8934	0.8904	0.8914
Arda Ölmez	Base	Deeper CNN	%88	0.88	0.88	0.88
Arda Ölmez	Advanced	ViT-B/16	%95.57	0.9570	0.9557	0.9559

- Tablo Yorumu ve Analizi**

Elde edilen sonuçlar (Tablo 1) incelendiğinde, Transfer Learning (Transfer Öğrenme) yöntemiyle eğitilen Gelişmiş Modellerin, sıfırdan eğitilen Base Modellere kıyasla genel doğruluk (accuracy) ve kararlılık açısından daha üstün olduğu görülmektedir.

Tablodan çıkarılan temel bulgular şunlardır:

- En Yüksek Başarı (SOTA Performansı):** Grubun en başarılı modeli, **%95.57** Doğruluk ve **0.9559** F1-Skoru ile Arda Ölmez tarafından eğitilen **Vision Transformer (ViT-B/16)** olmuştur. ViT modeli, Base modele kıyasla **%7.57**'lik dramatik bir performans artışı sağlayarak, "Attention" (Dikkat) mekanizmasının medikal görüntülemedeki gücünü kanıtlamıştır.

2. Mimari Karşılaştırması:

- **ResNet50 ve DenseNet121:** Sırasıyla %93.71 ve %92.19 başarı oranlarına ulaşarak %90 barajını rahatlıkla aşmışlardır. Bu durum, "Skip Connection" (Atlamalı Bağlantı) teknolojisinin derin ağlarda öğrenmeyi ne kadar iyileştirdiğini göstermektedir.
- **VGG16:** Mehmet Ali Esmer'in VGG16 modeli **%89.04** ile Base model (%89) seviyesinde kalmış ve %90 barajının marjinal olarak altında seyretmiştir. Bu durum, VGG mimarisinin modern mimarilere (ResNet, ViT) göre daha eski teknolojili ve optimize edilmesinin daha zor olmasına açıklanabilir.

3. **Genel Değerlendirme:** Base modeller ortalama %88.6 bandında bir başarı limiti (doygunluk noktası) sergilerken, Gelişmiş modeller (VGG hariç) bu limiti aşarak projeyi %92-%95 bandına taşımıştır. F1 skorlarının Accuracy değerleri ile paralellik göstermesi, uyguladığımız "Class Weighting" stratejisini işe yaradığını ve modellerin dengesiz veri setine rağmen tüm sınıfları (Glioma, Meningioma, Pituitary, No Tumor) dengeli bir şekilde öğrendiğini kanıtlamaktadır.
4. **Sonuç:** Proje hedeflerinde belirtilen "Gelişmiş Mimariler" stratejisi, özellikle Transformer ve Residual tabanlı modellerde hedeflenen başarı kriterlerini fazlaıyla karşılamıştır.

- **Sınıf Bazlı Başarım Karşılaştırması**

Tıbbi görüntü analizinde genel doğruluk kadar, her bir tümör tipinin (Glioma, Meningioma, Pituitary) ne kadar doğru tespit edildiği de kritiktir. Aşağıdaki tablo, modellerin her bir sınıf özelindeki ayırt etme gücünü F1-Score metriği üzerinden karşılaştırmaktadır.

*Tablo 2: Modellerin Sınıf Bazlı Performans Analizi
(F1-Score Karşılaştırması / Her sınıf sütunu için en iyi model kalın font işaretlenmiştir.)*

Model Adı (Mimari)	Glioma (F1)	Meningioma (F1)	Pituitary (F1)	No Tumor (F1)
Base: Simple CNN	0.89	0.86	0.87	0.95
Base: Large Kernel	0.86	0.83	0.88	0.97
Base: Dropout	0.87	0.84	0.91	0.96
Base: High Capacity	0.88	0.85	0.88	0.95
Base: Deeper	0.88	0.82	0.87	0.95
Adv: ResNet50	0.9091	0.8827	0.9750	0.9638
Adv: DenseNet121	0.9247	0.8451	0.9634	0.9369
Adv: EfficientNet - B0	0.8870	0.8116	0.9540	0.9437
Adv: VGG16	0.8723	0.7828	0.9672	0.9129
Adv: ViT-B/16	0.9301	0.9188	0.9826	0.9792

- **Sınıf Bazlı Analiz Yorumu**

1. **En Zor Sınıf (Meningioma):** Analiz sonuçlarına göre modellerin sınıflandırmakta en çok güçlük çektüğü sınıf Meningioma olmuştur. Tablo incelendiğinde, Base modellerin ortalama 0.84 seviyesinde kaldığı, VGG16 gibi bazı gelişmiş modellerin ise 0.78 seviyesine kadar düştüğü görülmektedir. Bu durum, Meningioma tümörünün doku yapısının Glioma ile olan yüksek görsel benzerliğinden ve tümör sınırlarının (segmentasyon zorluğu) belirsizliğinden kaynaklanmaktadır. Modellerin çoğu bu sınıfı diğerleriyle karıştırma eğilimi göstermiştir.
2. **En Başarılı Sınıf (Pituitary ve No Tumor):** Tümör bulunmayan (**No Tumor**) ve Hipofiz (**Pituitary**) sınıfları, ayırt edici özelliklerinin (anatomik konum ve doku parlaklısı) daha net olması sebebiyle tüm modellerde en yüksek F1 skorlarını almıştır. Özellikle Pituitary tümörü, **Vision Transformer (ViT)** modelinde **0.9826** gibi neredeyse kusursuz bir başarı oranına ulaşarak, modelin bu sınıfı öğrenme kapasitesinin çok yüksek olduğunu kanıtlamıştır.
3. **Gelişmiş Modellerin Etkisi:** Gelişmiş modellerin etkisi, özellikle zorlu sınıfların ayrılmada belirginleşmiştir. **Vision Transformer (ViT-B/16)** modeli, en zor sınıf olan Meningioma ve Glioma ayrılmada Base modellere kıyasla çığır açıcı bir iyileşme sağlamıştır.
 - Base modellerin Meningioma için ulaşabildiği en yüksek skor **0.86** iken, ViT modeli bu skoru **0.9188**'e taşımıştır.
 - Bu başarı, ViT mimarisinin sadece lokal piksellere değil, "**Self-Attention**" mekanizması sayesinde görüntünün bütününe odaklanarak, CNN modellerinin kaçırduğu ince doku farklarını yakalayabilmesiyle açıklanabilir.
4. **Sonuç:** Sınıf bazlı analizler, projenin "Advanced Model" stratejisinin özellikle zorlu ve birbirine benzeyen tümör türlerinin (Meningioma/Glioma) ayrılmında hayatı bir rol oynadığını doğrulamaktadır. Base modellerin yetersiz kaldığı detaylarda, **Vision Transformer** ve **DenseNet/ResNet** gibi modern mimariler gerekli hassasiyeti sağlamıştır.

9. KAYNAKLAR

- [1] S. Bhuvaji, et al., "Brain Tumor Classification (MRI)," Kaggle, 2020. [Online]. Available:
<https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>
- [2] M. Nickparvar, "Brain Tumor MRI Dataset," Kaggle, 2021. [Online]. Available:
<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>
- [3] S. Pereira, A. Pinto, V. Alves, and C. A. Silva, "Brain tumor segmentation using convolutional neural networks in MRI images," *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1240–1251, 2016.
- [4] N. Abiwinanda, M. Hanif, S. T. Heswara, A. Hezer, and T. R. Mengko, "Brain Tumor Classification Using Convolutional Neural Network," in *World Congress on Medical Physics and Biomedical Engineering*, Springer, 2019, pp. 183-189. (Not: Sığ modeller için iyi bir referans).
- [5] A. Rehman, et al., "Microscopic Brain Tumor Detection and Classification Using 3D CNN and Feature Selection Architecture," *Microscopy Research and Technique*, vol. 84, no. 1, 2021.
- [6] J. Seetha and S. S. Raja, "Brain Tumor Classification Using Convolutional Neural Networks," *Biomedical & Pharmacology Journal*, vol. 11, no. 3, pp. 1457-1461, 2018.
- [7] M. Talo, et al., "Convolutional neural networks for multi-class brain disease detection using MRI images," *Computerized Medical Imaging and Graphics*, vol. 78, 2019.