




PROJE BAŞLIĞI: MRI GÖRÜNTÜLERİNDEN BEYİN TÜMÖRÜ SINIFLANDIRMASI: FARKLI SIĞ (SHALLOW) CNN MİMARİLERİNİN KARŞILAŞTIRMALI ANALİZİ

EKİP ADI: DevTe213



EKİP ÜYELERİ:

1. Mehmet Ali Esmer	Öğrenci No: 23040101013	E-posta: mehmetallesmer@stu.topkapi.edu.tr
2. Arda Ölmez	Öğrenci No: 23040101019	E-posta: ardadimez@stu.topkapl.edu.tr
3. Bilal Furkan Çakırğöz	Öğrenci No: 23040101021	E-posta: bilaifurkancakirgor@stu.topkapl.edu.tr
4. Burak Şabin	Öğrenci No: 23040101072	E-posta: buraksahin@stu.topkapl.edu.tr
5. Muhammed Emin Benzer	Öğrenci No: 23040101045	E-posta: muhammedeminbenzer@stu.topkapl.edu.tr

PROJE GITHUB BAĞLANTISI:  https://github.com/olmezarda/FET312_BrainTumor_Project

TESLİM TARİHİ: 30 KASIM 2025

1. PROBLEM TANIMI & MOTİVASYON

- **İş/Bilimsel Soru**

Beyin tümörleri, erken teşhis edilmediğinde ölümcül sonuçlara yol açabilen ciddi sağlık sorunlarıdır. Radyologların MRI görüntülerini manuel olarak incelemesi zaman alıcıdır, yorucudur ve insan hatasına açıktır. Bu projenin temel motivasyonu, MRI görüntülerini analiz ederek tümör varlığını ve tipini otomatik olarak tespit edebilen, radyologlara karar destek mekanizması sunacak güvenilir bir derin öğrenme sistemi geliştirmektir.

- **Görev Türü**

Çok Sınıflı Görüntü Sınıflandırma (Multi-class Image Classification).

- **Hedef Değişkenler**

Modelin tahmin etmesi gereken 4 farklı sınıf bulunmaktadır:

1. Glioma Tumor
2. Meningioma Tumor
3. Pituitary Tumor (Hipofiz Tümörü)
4. No Tumor (Tümör Yok)

- **Başarı Kriterleri**

1. Geliştirilecek sıg (base) modeller için Accuracy (Doğruluk) \geq %80.
2. Dengesiz veri dağılımı ihtimaline karşı Weighted F1-Score \geq 0.75.
3. Final projesinde hedeflenen gelişmiş mimariler için Accuracy \geq %90.

2. PROJE YÖNETİMİ

- **Önemli Noktalar ve Zaman Çizelgesi (Timeline)**

1. 1. Hafta (Ekim Sonu): Kaggle veri setinin incelenmesi, literatür taraması ve görev dağılımı.
2. 2. Hafta (Kasım Başı): Veri ön işleme (Pre-processing), yeniden boyutlandırma ve PyTorch DataLoader yapısının kurulması.
3. 3. Hafta (Kasım Ortası): 5 farklı Base Model (Shallow CNN) mimarisinin tasarlanması ve her grup üyesinin kendi modelini kodlaması.
4. 4. Hafta (30 Kasım'a Kadar): Base modellerin eğitimi, validasyon testleri, sonuçların karşılaştırılması ve İlerleme Raporunun teslimi.
5. 5-8. Hafta (Final Dönemi): Transfer Learning (ResNet, EfficientNet) ve Vision Transformer (ViT) gibi gelişmiş modellerin entegrasyonu ve final sunumu.

- **Roller ve Sorumluluklar (Base Model Dağılımı)**

Tüm grup üyeleri veri seti inceleme ve hazırlama aşamasında ortak çalışmıştır. Ayrışılan nokta model mimarileridir:

1. **Muhammed Emin Benzer:**

- **Base Model:** Referans noktası oluşturmak amacıyla standart 3x3 Konvolüsyon ve MaxPooling katmanlarından oluşan 2 blokluya sahip model.
- **Final Hedefi: ResNet50 (Residual Networks):** Artık (residual) bağlantıların derin ağlardaki kaybolan gradyan sorununu nasıl çözdüğünü analiz edecek ve bu mimariyi transfer learning ile veri setine uyarlayacaktır.

2. **Burak Şahin:**

- **Base Model:** Tümörün çevresel bağlamını ve daha büyük desenleri yakalamak amacıyla geniş filtreli (Kernel Size: 5x5 veya 7x7) mimari.
- **Final Hedefi: InceptionV3 (GoogleNet):** Farklı boyutlardaki filtrelerin paralel olarak çalıştığı Inception modüllerini kullanarak, tümörün hem ince detaylarını hem de genel yapısını aynı anda yakalamayı hedefleyecektir.

3. **Bilal Furkan Çakırgöz:**

- **Base Model:** Veri setindeki ezberleme (overfitting) riskini minimize etmek için katmanlar arasına "Dropout" (Sönümleme) eklenmiş mimari.
- **Final Hedefi: EfficientNet:** Model boyutu ile doğruluk (accuracy) arasındaki dengeyi optimize eden EfficientNet ailesini kullanarak, daha az parametre ile yüksek başarı elde etmeye odaklanacaktır.

4. **Mehmet Ali Esmer:**

- **Base Model:** Modelin öznetelik çıkarma kapasitesini artırmak için her katmanda kullanılan filtre sayısının (channel depth) iki katına çıkarıldığı mimari.
- **Final Hedefi: VGG16 / VGG19:** Derin ve standart konvolüsyon yapılarının (klasik derin mimarilerin) medikal görüntülerdeki başarısını, sıkı modellerle kıyaslamalı olarak inceleyecektir.

5. **Arda Ölmez:**

- **Base Model:** Sıkı modellerde katman sayısının etkisini ölçmek amacıyla, standart mimariye ekstra bir Konvolüsyon bloğu daha eklenerek derinleştirilmiş (3 blokluya sahip) mimari.
- **Final Hedefi: Vision Transformer (ViT):** CNN tabanlı olmayan, "Attention" mekanizmasına dayalı Transformer mimarisini medikal görüntülere uygulayarak, CNN modelleri ile performans farkını (SOTA) araştıracaktır.

- **Çıktılar**

1. Proje İlerleme Raporu (PDF).
2. 5 adet farklı PyTorch Jupyter Notebook (.ipynb).
3. Eğitimloss/accuracy grafikleri ve confusion matrix çıktıları.
4. **Repo Bağlantısı:** https://github.com/olmezarda/FET312_BrainTumor_Project

- **NOT :** Proje takvimine uygun olarak test süreçleri devam etmektedir. İlgili kod dosyaları ve performans çıktıları, son teslim tarihi olan **30 Kasım 2025 saat 23.59'a kadar** tamamlanarak GitHub reposuna ve ALMS sistemine eksiksiz olarak yüklenecektir.

3. İLGİLİ ÇALIŞMALAR

- **Sartaj Bhuvaji et al. (2020) - Dataset Owner:** Veri setinin yayınlandığı bu temel çalışmada, Glioma ve Meningioma tümörlerinin ayırt edilmesinde klasik CNN yapılarının başarısı incelenmiş ve doğruluk oranları raporlanmıştır.
Farkımız: Bu çalışma standart bir CNN kullanırken; bizim projemiz aynı veri seti üzerinde **5 farklı mimari stratejisini** (Kernel Size değişimi, Dropout etkisi, Derinlik farkı vb.) izole ederek karşılaştırmalı bir analiz sunmaktadır.
- **Masoud Nickparvar, "Brain Tumor MRI Dataset" (Kaggle):** Literatürde sıkça kullanılan bu veri seti, farklı kaynakların birleştirilmesiyle oluşturulmuş ve 7.000'den fazla görüntü içeren kapsamlı bir koleksiyondur. Genellikle derin öğrenme modellerinin büyük ölçekli veri üzerindeki eğitim başarısını test etmek için standart bir benchmark olarak kullanılır.
Farkımız: Biz bu projede, birleştirilmiş (merged) devasa bir veri seti yerine; Sartaj Bhuvaji'nin setini kullanarak, daha sınırlı veri senaryolarında "Mimarinin" etkisini izole etmeye odaklanıyoruz. Masoud veri seti, geliştirdiğimiz modellerin farklı veri dağılımlarındaki başarısını (cross-dataset validation) doğrulamak amacıyla final aşamasında harici bir referans noktası olarak değerlendirilecektir.
- **Abiwinanda et al., "Brain Tumor Classification Using Convolutional Neural Network" (2019):** Bu çalışmada, beyin tümörü sınıflandırması için karmaşık ağlar yerine, sıfırdan eğitilen (scratch) basit bir CNN mimarisi önerilmiş ve %84.19 başarı elde edilmiştir. Çalışma, sığ modellerin de belirli bir başarıya ulaşabileceğini kanıtlaması açısından önemlidir.
Farkımız: Abiwinanda tek bir sığ mimari önermiştir. Bizim projemiz ise sığ modellerin sınırlarını zorlamak için **"Genişlik (Width) vs Derinlik (Depth)"** ve **"Regularizasyon"** tekniklerinin etkisini ayrı ayrı deneyimleyerek, sığ modellerin maksimum potansiyelini araştırmayı hedeflemektedir.
- **Talo et al. (2019):** ResNet-34 mimarisi ile %95 üzeri başarı elde ederek, derin ağların sığ modellere kıyasla doku detaylarını yakalamadaki üstünlüğünü kanıtlamıştır.
Farkımız: Bu çalışmadan farklı olarak; sığ modellerin (vize) kaçırdığı vakaların (False Negatives), ResNet ve ViT gibi gelişmiş mimarilerle (final) ne oranda düzeltilebileceğini analiz eden aşamalı bir iyileştirme raporu sunacağız.

4. VERİ AÇIKLAMASI VE YÖNETİMİ

• Veri Kümesi

- Proje kapsamında, modelin eğitim başarısını artırmak ve veri çeşitliliğini sağlamak amacıyla Kaggle platformunda yer alan ve literatürde benchmark olarak kabul edilen iki temel açık kaynak veri seti referans alınmıştır:

1. **Sartaj Bhuvaji (Dataset Owner):** Brain Tumor Classification (MRI)

Bağlantı:

<https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>

2. **Masoud Nickparvar:** Brain Tumor MRI Dataset

Bağlantı:

<https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>

- **Lisans ve Kullanım Hakları:** Her iki veri seti de açık akademik kullanım lisansına (Open Source / Public Domain) sahiptir. İçerdiği tıbbi görüntülerde hasta mahremiyetini ihlal edecek herhangi bir kişisel veri bulunmamakta olup, tüm veriler anonimleştirilmiştir (de-identified). Bu nedenle etik kurul onayı gerektirmeden eğitim ve araştırma amaçlı kullanımı uygundur.

• Sema ve Boyut

- **İçerik:** Sartaj Bhuvaji (3.264 görüntü) ve Masoud Nickparvar (~7.023 görüntü) veri setleri, farklı düzlemlerdeki beyin MRI taramalarından oluşmaktadır.
- **Format:** Tüm veriler JPG/PNG formatındadır ve proje kapsamında standart bir boyuta (örn. 128x128 piksel) getirilerek (Resize) normalize edilecektir.
- **Sınıf Dağılımı:** Her iki veri seti de aynı **4 ana sınıf** etiketine sahiptir:
 1. Glioma Tumor
 2. Meningioma Tumor
 3. Pituitary Tumor
 4. No Tumor

• Veri Yönetimi Ve Etik

Veriler halka açık (Public Domain) lisanslıdır. Medikal veriler anonimleştirilmiş olduğu için gizlilik ihlali oluşturmamaktadır.

5. YÖNTEMLER VE MİMARİ

- **Yöntem**

Bu projede problem, **Denetimli Öğrenme (Supervised Learning)** kapsamında "Çok Sınıflı Görüntü Sınıflandırma" problemi olarak ele alınacaktır. Çözüm mimarisi olarak, görüntü verilerinden mekansal öznitelikleri (spatial features) otomatik olarak çıkarabilme ve hiyerarşik desenleri öğrenebilme yeteneği nedeniyle **Evrışimli Sinir Ağları (Convolutional Neural Networks - CNN)** kullanılacaktır. Proje geliştirme sürecinde **PyTorch** derin öğrenme kütüphanesi kullanılacak olup, hazır mimariler yerine her grup üyesinin kendi tasarladığı özgün **"Custom CNN"** sınıfı nn.Module üzerinden inşa edilecektir.

- **Veri Ön İşleme**

Veri seti modele verilmeden önce aşağıdaki standart boru hattından (pipeline) geçirilecektir:

1. **Yeniden Boyutlandırma (Resizing):** Farklı çözünürlükteki tüm MRI görüntüleri, işlem yükünü optimize etmek için 128x128 piksel boyutuna sabitlenecektir.
2. **Tensör Dönüşümü:** Görüntüler ToTensor() fonksiyonu ile PyTorch tensör formatına çevrilecektir.
3. **Normalizasyon:** Piksel yoğunluk değerleri, modelin daha hızlı yakınsaması (convergence) için [0, 1] aralığına ölçeklendirilecek ve ImageNet standartlarına (mean: 0.5, std: 0.5) göre normalize edilecektir.
4. **Veri Artırma (Data Augmentation - Final Aşaması):** Eğitim verisini çeşitlendirmek ve ezberlemeyi önlemek amacıyla final aşamasında RandomHorizontalFlip ve RandomRotation teknikleri uygulanacaktır.

- **Eğitim Süreci ve Hiper-Parametre Stratejisi**

Modellerin eğitimi sırasında aşağıdaki konfigürasyon benimsenecektir:

1. **Hata Fonksiyonu (Loss Function):** Çoklu sınıf ayrımı yapıldığı için **CrossEntropyLoss** kullanılacaktır.
2. **Optimizasyon:** Gradyan inişini optimize etmek ve adaptif öğrenme oranı sağlamak için **Adam Optimizer** (Learning Rate: 0.001) tercih edilmiştir.
3. **Eğitim Döngüsü:** Modeller 15-20 Epoch boyunca eğitilecek, her epoch sonunda validasyon setindeki başarı (accuracy) ve kayıp (loss) değerleri izlenecektir.
4. **Hiper-Parametre Optimizasyonu:** Vize aşamasında manuel ayarlama (manual tuning) yöntemiyle Batch Size (32/64) ve Learning Rate parametreleri test edilecektir.

- **Grup Üyelerinin Mimari Tasarımları**

Her grup üyesi, CNN mimarisinin farklı bir bileşeninin etkisini analiz etmek üzere ayrılmış mimariler tasarlamıştır:

1. Muhammed Emin Benzer (Baseline Model):

- **Mimari:** 2 adet Conv2d (3x3, 16-32 filtre) katmanı, her birini takip eden ReLU aktivasyonu ve MaxPooling katmanından oluşur.
- **Amaç:** Karmaşıklıştırmadan önce modelin ham başarısını ölçmek.

2. Burak Şahin (Large Kernel Model):

- **Mimari:** Baseline model ile aynı derinlikte olup, filtre boyutu 3x3 yerine 7x7 olarak ayarlanmıştır.
- **Amaç:** Daha geniş bir alıcı alan (Receptive Field) kullanarak tümörün çevresel dokuyla ilişkisini yakalamak.

3. Bilal Furkan Çakırgöz (Dropout Model):

- **Mimari:** Tam bağlantılı (Fully Connected) katmanlar arasına %50 ($p=0.5$) oranında Dropout katmanları eklenmiştir.
- **Amaç:** Nöronların rastgele kapatılmasıyla modelin eğitim verisine aşırı uyum sağlamasını (overfitting) engellemek.

4. Mehmet Ali Esmer (High Capacity Model):

- **Mimari:** Her konvolüsyon katmanındaki kanal sayısı (feature maps) standart modelin iki katına (32 ve 64 filtre) çıkarılmıştır.
- **Amaç:** Modelin öğrenme kapasitesini (width) artırarak daha karmaşık öz nitelikleri yakalamasını sağlamak.

5. Arda Ölmez (Deeper Model):

- **Mimari:** Modele ekstra bir Conv2d + ReLU + MaxPool bloğu daha eklenerek toplam derinlik 3 bloğa çıkarılmıştır.
- **Amaç:** Katman sayısını artırmanın (derinleşmenin) sıkı modellere kıyasla öz nitelik hiyerarşisine etkisini gözlemlemek.

6. DENEY TASARIMI

• Eğitim/Test Ayrımı

Veri seti %70 Eğitim, %15 Doğrulama ve %15 Test seti olarak ayrılacaktır.

• Hiper-Parametreler

1. **Optimizer:** Adam (Adaptive learning rate) - Başlangıç LR: 0.001.
2. **Loss Function:** CrossEntropyLoss (Multi-class classification için).
3. **Batch Size:** 32 veya 64.
4. **Epoch:** Early Stopping mekanizması ile maksimum 20-30 epoch.

• Değerlendirme Kriterleri

Modellerin başarısı sadece Accuracy ile değil, yanlış negatifleri (Tümör var ama yok dediğimiz durumlar) cezalandırmak adına **Recall** ve **Confusion Matrix** üzerinden yorumlanacaktır.

7. KULLANILAN ARAÇLAR VE FRAMEWORKLER

- **Yazılım & Kütüphaneler:** Proje, **Python 3.10+** ve **PyTorch (v2.x)** tabanında geliştirilecektir.
 - **Veri & Metrik:** NumPy, Pandas, Scikit-learn.
 - **Görselleştirme:** Matplotlib, Seaborn.
- **Tekrarlanabilirlik:** Veri ayrımında (split) tutarlılık sağlamak amacıyla grup genelinde ortak **Random Seed: 213** kullanılacaktır.
- **Donanım:** Eğitimler lokal **CUDA destekli NVIDIA GPU** ortamlarında gerçekleştirilecektir.
- **Repo Bağlantısı:** Geliştirilen kaynak kodlar ve notebook dosyaları erişime açıktır: https://github.com/olmezarda/FET312_BrainTumor_Project

8. ÖN DENEYSEL SONUÇLAR VE TARTIŞMA

- Proje takvimine uygun olarak 5 farklı Base Modelin kodlaması tamamlanmış ve ilk eğitim fazı başlatılmıştır. Hiper-parametre optimizasyonu devam eden modellerin, rastgele tahmin başarısını aştığını gösteren **ilk ham sonuçları (Preliminary Results)** aşağıda sunulmuştur. 30 Kasım teslimine kadar yapılacak iyileştirmelerle, mevcut başarının hedeflenen **%80** ve üzeri bandına taşınması planlanmaktadır.
- **Bulguların Yorumlanması ve Geliştirme Planı:**
Mevcut erken aşama sonuçları incelendiğinde şu teknik çıkarımlar yapılmıştır:
 1. **Kapasite Etkisi:** Mehmet Ali Esmer'in geliştirdiği High Capacity (Geniş Kanal) modeli, erken aşamada en yüksek başarıyı (%61.50) göstererek, sık modellerde nöron sayısını (width) artırmanın öğrenmeyi hızlandırdığını kanıtlamıştır.
 2. **Regularizasyon Etkisi:** Bilal Furkan Çakırgöz'ün modelindeki Dropout katmanları, beklendiği gibi ilk aşamada doğruluğu baskılamıştır (%48.90). Ancak epoch sayısı arttıkça bu modelin validasyon başarısının diğerlerini yakalaması ve geçmesi beklenmektedir.
 3. **Genel Durum:** Tüm modellerin loss değerleri düşüş eğilimindedir, bu da mimarilerin doğru kurulduğunu ve öğrenmenin gerçekleştiğini doğrulamaktadır.

NOT : Proje takvimine uygun olarak model geliştirme süreçleri devam etmektedir. Modellerin nihai performanslarını gösteren detaylı çıktılar (**Confusion Matrix, ROC Eğrileri, Loss Grafikleri ve Final Accuracy Değerleri**), son teslim tarihi olan **30 Kasım 2025 saat 23.59'a kadar** tamamlanarak GitHub reposuna ve ALMS sistemine eksiksiz olarak yüklenecektir.

Grup Üyesi & Model	Mimari Stratejisi	Accuracy (%)	Gözlemlenen Durum
1. M. Emin Benzer (Baseline)	Standart 3x3 CNN	%52.40	Model öğrenmeye başladı ancak loss değeri henüz stabilize olmadı.
2. Burak Şahin (Large Kernel)	Geniş Filtre (7x7)	%55.10	Büyük filtreler, tümörlü görüntüleri yakalamada şimdiden küçük bir fark yarattı.
3. B. Furkan Çakırgöz (Dropout)	Dropout (%50)	%48.90	Dropout eklediğimiz için modelin öğrenmesi yavaş ilerliyor (beklenen durum), ancak ezberleme (overfitting) yapmıyor.
4. Mehmet Ali Esmer (High Cap.)	Geniş Kanal (64)	%61.50	Kapasite artışı sayesinde modele en hızlı adapte olan mimari şu an için bu oldu.
5. Arda Ölmez (Deeper)	3-Blok Derinlik	%58.20	Derinlik artışı pozitif etki gösterdi, eğitim süresi diğerlerine göre daha uzun sürüyor.

NOT : Bu proje raporu kapsamında geliştirilen 5 farklı Base Model mimarisine ait detaylı performans analizleri (Eğitim/Validasyon Loss eğrileri, Accuracy değişim grafikleri, Confusion Matrix görselleştirmeleri ve Sınıflandırma Raporları), her grup üyesi tarafından ayrı ayrı hazırlanan Jupyter Notebook (.ipynb) kaynak kod dosyaları içerisine entegre edilmiştir.

Proje teslim gereksinimleri doğrultusunda, statik bir PDF dosyasının sayfa sınırlarını aşmamak ve çıktıların etkileşimli (interactive) yapısını korumak amacıyla; tüm görselleştirme ve performans metrikleri ilgili kod dosyalarının "Output" (Çıktı) hücrelerinde sunulmuştur.

- Eğitim Analizi:** Epoch bazlı Train vs Validation Loss ve Accuracy grafik karşılaştırmaları.
- Sınıflandırma Başarısı:** Her model için renkli Confusion Matrix (Heatmap) görselleştirmesi.
- Metrik Tabloları:** Precision, Recall ve F1-Score değerlerini içeren detaylı sınıflandırma raporları.

Tüm bu grafikler ve sayısal veriler, projenin dijital teslim paketi olan ALMS sistemi ve GitHub deposu üzerinden erişilebilir durumdadır.

9. KAYNAKLAR

- [1] S. Bhuvaji, et al., "Brain Tumor Classification (MRI)," Kaggle, 2020. [Online]. Available: <https://www.kaggle.com/datasets/sartajbhuvaji/brain-tumor-classification-mri>
- [2] M. Nickparvar, "Brain Tumor MRI Dataset," Kaggle, 2021. [Online]. Available: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>
- [3] S. Pereira, A. Pinto, V. Alves, and C. A. Silva, "Brain tumor segmentation using convolutional neural networks in MRI images," *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1240–1251, 2016.
- [4] N. Abiwinanda, M. Hanif, S. T. Heswara, A. Hezer, and T. R. Mengko, "Brain Tumor Classification Using Convolutional Neural Network," in *World Congress on Medical Physics and Biomedical Engineering*, Springer, 2019, pp. 183-189. (Not: Sığ modeller için iyi bir referans).
- [5] A. Rehman, et al., "Microscopic Brain Tumor Detection and Classification Using 3D CNN and Feature Selection Architecture," *Microscopy Research and Technique*, vol. 84, no. 1, 2021.
- [6] J. Seetha and S. S. Raja, "Brain Tumor Classification Using Convolutional Neural Networks," *Biomedical & Pharmacology Journal*, vol. 11, no. 3, pp. 1457-1461, 2018.
- [7] M. Talo, et al., "Convolutional neural networks for multi-class brain disease detection using MRI images," *Computerized Medical Imaging and Graphics*, vol. 78, 2019.